



T2: Matching de Produtos

Aprendizado de Máquina

Prof. Me. Otávio Parraga

No primeiro trabalho, o foco foi explorar algoritmos de aprendizado de máquina supervisionado aplicados a dados estruturados. Neste T2, o desafio é diferente: trabalharemos com dados textuais não estruturados em um problema real trazido por uma empresa parceira — a Nubo Desenvolvimento de Software LTDA.

O problema consiste em identificar automaticamente, a partir de um texto de consulta escrito de forma heterogênea e sem padronização, qual é o produto correspondente em um catálogo normalizado. Trata-se de um problema clássico de **recuperação de informação**, com alta relevância prática em sistemas de compras, gestão de estoque e integração entre bases de dados de fornecedores distintos.

Contexto

Distribuidoras e varejistas do setor de bebidas e alimentos frequentemente recebem pedidos de compra escritos de formas completamente diferentes: abreviações, erros ortográficos, variações de embalagem, ausência de unidades de medida padronizadas. O mesmo produto pode aparecer como:

Texto da Consulta (query)	Produto no Catálogo
COCA COLA 1L C/6	Refrigerante coca-cola pet 1 litro
SKOL LATA 350ml C/12	Cerveja skol lata 350ml
FANTA LARANJA 2L C/6	Refrigerante fanta laranja 2 litros
MONSTER BRANCO S/ACUCAR C/6 UNID	Energético monster energy zero açúcar lata 473ml

Fazer esse mapeamento manualmente, para milhares de pedidos por dia, é inviável. O objetivo deste trabalho é construir e avaliar pipelines automáticos de matching utilizando duas abordagens distintas de processamento de linguagem natural.

Dados Fornecidos

Você receberá quatro arquivos CSV:

`catalog.csv` — Catálogo Normalizado de Produtos

Contém as seguintes colunas:

Coluna	Descrição	Exemplo
<code>product_id</code>	Código EAN/GTIN único do produto	07891991014915
<code>product_name</code>	Nome padronizado do produto	Refrigerante guaraná antarctica 200ml
<code>brand_name</code>	Marca do produto	Antarctica

`queries.csv` — Consultas de Produtos

Contém as seguintes colunas:

Coluna	Descrição	Exemplo
<code>text</code>	Texto heterogêneo da consulta	FANTA LARANJA 2L C/6
<code>matched_id</code>	<code>product_id</code> correto (inicialmente vazio)	(a ser preenchido pelo grupo)

A coluna `matched_id` estará vazia para todas as linhas. Este arquivo pode ser utilizado para exploração, análise dos dados e modelagem. Idealmente, utilize este conjunto para desenvolver e ajustar seus pipelines, juntamente ao `queries_val.csv`.

`queries_val.csv` e `queries_test.csv` — Conjuntos de Validação e Teste

Ambos contêm **250 queries anotadas** pelo professor, com `matched_id` preenchido. O conjunto de validação deve ser utilizado durante o desenvolvimento para ajustar parâmetros e comparar variações. O conjunto de teste deve ser utilizado somente ao final, para reportar as métricas definitivas.

Coluna	Descrição
<code>text</code>	Texto heterogêneo da consulta
<code>matched_id</code>	<code>product_id</code> correto (preenchido)

Etapas Esperadas

Ao final do trabalho, espera-se que o grupo elabore e reporte os seguintes passos:

1. **Exploração dos dados:** carregue `catalog.csv` e `queries.csv`. Analise a distribuição dos dados, identifique padrões nas queries (abreviações frequentes, categorias de produtos) e casos que pareçam desafiadores.
2. **Abordagem 1 — NLP Clássico:** implemente o pipeline com TF-IDF ou BM25, calcule as métricas $P@1$, MRR e $R@5$ sobre `queries_val.csv` e registre os resultados.
3. **Abordagem 2 — NLP com Deep Learning:** implemente o pipeline com um modelo de rede neural, calcule as mesmas métricas sobre `queries_val.csv` e registre os resultados.
4. **Comparação das abordagens:** construa a tabela comparativa (métricas, tempo de execução, custo, complexidade) e discuta: em quais tipos de query cada abordagem se saiu melhor? Qual é o tradeoff entre simplicidade e desempenho?
5. **Avaliação final:** após finalizar o desenvolvimento, reporte as métricas finais de ambas as abordagens sobre `queries_test.csv`.
6. **Análise qualitativa:** apresente exemplos de acertos, erros e casos ambíguos para cada abordagem.
7. **Relatório e apresentação:** documente toda a metodologia, os resultados e as conclusões conforme descrito na seção de Entrega.

Abordagens

Abordagem 1 — NLP Clássico

A primeira abordagem utiliza técnicas tradicionais de recuperação de informação baseadas em similaridade textual. O pipeline consiste em:

1.1 Pré-processamento Textual

Antes de calcular qualquer similaridade, ambos os textos (query e nome do produto no catálogo) devem ser normalizados. Recomenda-se aplicar ao menos:

- Conversão para minúsculas
- Remoção de pontuação e caracteres especiais
- Remoção de stopwords em português (ex: "de", "do", "com", "sem", "por")
- Normalização de abreviações comuns (ex: `ML` → `ml`, `L` → `litro`)
- Remoção de termos irrelevantes para o matching (ex: quantidades de embalagem como `C/6`, `C/12`, `UND`)

1.2 Representação Vetorial e Busca por Similaridade

Após o pré-processamento, represente os textos como vetores e calcule a similaridade entre a query e cada produto do catálogo. Duas opções são sugeridas (implemente ao menos uma):

TF-IDF com Similaridade de Cosseno: Como trabalhamos no desafio II do Kaggle, nesta abordagem montamos matrizes baseadas em frequência de termos, ponderados por TF-IDF, e calculamos a similaridade de cosseno entre a query e os produtos do catálogo.

BM25: BM25 é um algoritmo de ranqueamento probabilístico amplamente utilizado em motores de busca, geralmente superior ao TF-IDF para textos curtos.

Para cada query no conjunto avaliado, o pipeline deve:

1. Pré-processar o texto da query
2. Calcular a similaridade com todos os produtos do catálogo
3. Retornar os **top-5 produtos** mais similares com suas pontuações
4. Registrar o `product_id` do produto ranqueado em 1º lugar como predição principal

Abordagem 2 — Deep Learning

A segunda abordagem deve utilizar um modelo de rede neural. A escolha do modelo e, se necessário, do provedor fica a critério do grupo — o que importa é que seja uma abordagem baseada em redes neurais. Caso optem por rodar localmente os modelos, podem recorrer ao uso do [Hugging Face Hub](#), [Sentence-Transformer](#), ou também pelo [Ollama](#)). Caso usem API, sugiro a [API do Google Gemini](#) por ser gratuita e ter limites generosos de uso, mas outras opções (OpenAI, Anthropic, etc.) também são válidas. Para trabalhar com LLMs duas estratégias são sugeridas:

Embeddings Semânticos: Podemos gerar embeddings para as queries e para os produtos do catálogo usando um modelo de embedding, depois calcular a similaridade de cosseno entre eles. O pipeline seria semelhante ao da abordagem clássica, mas utilizando vetores densos gerados por um modelo de linguagem em vez de vetores esparsos baseados em frequência.

Zero-Shot ou Few-Shot Prompting: Alternativamente, podemos pedir diretamente a um modelo LLM que identifique o produto mais provável dado um contexto. Por exemplo, fornecendo a query e uma lista dos top-10 candidatos (filtrados previamente por BM25), o modelo pode escolher o produto mais adequado. Ao não fornecer nenhum exemplo, temos o cenário zero-shot; ao fornecer alguns exemplos de correspondências corretas, temos o cenário few-shot.

Para os dois cenários com Deep Learning, recomendo que usem em combinação com a Abordagem 1. Primeiro filtre os top-10 candidatos via BM25 ou TF-IDF, depois passe esses candidatos a rede para a decisão final. Isso reduz drasticamente o consumo de tokens e custo computacional e melhora a qualidade das respostas.

Avaliação

Conjuntos de Avaliação

Os arquivos `queries_val.csv` e `queries_test.csv` contêm 250 queries cada, com a coluna `matched_id` já preenchida pelo professor.

- `queries_val.csv` (validação): use durante o desenvolvimento para ajustar parâmetros, comparar variações e decidir entre abordagens.
- `queries_test.csv` (teste): use **somente ao final**, para reportar as métricas definitivas. Não o utilize para tomar decisões de desenvolvimento!

Métricas de Avaliação

Calcule as seguintes métricas para **cada abordagem** sobre os conjuntos de avaliação.

Precision@1 (P@1)

Mede se o produto retornado em primeiro lugar está correto. É a métrica mais intuitiva para um sistema de matching com uma única predição principal.

$$P@1 = \frac{\text{número de queries em que o produto correto foi ranqueado em 1º lugar}}{\text{número total de queries avaliadas}}$$

Exemplo: se de 50 queries anotadas, 32 tiveram o produto correto em 1º lugar $\rightarrow P@1 = 32/50 = 0,64$.

MRR — Mean Reciprocal Rank

Considera não apenas se o produto correto foi retornado, mas em qual posição ele aparece na lista de resultados. É especialmente útil quando o sistema retorna uma lista ranqueada (top-5), pois dá crédito parcial a acertos nas posições 2, 3, 4 e 5.

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

onde rank_i é a posição do produto correto na lista de resultados para a query i (se não aparecer no top-5, considera-se $\frac{1}{\text{rank}_i} = 0$). Neste trabalho, adotamos $K = 5$, ou seja, calculamos o **MRR@5**.

Exemplo: para 3 queries com o produto correto nas posições 1, 3 e 2:

$$MRR = \frac{1}{3} \left(\frac{1}{1} + \frac{1}{3} + \frac{1}{2} \right) = \frac{1}{3} (1,0 + 0,33 + 0,5) \approx 0,61$$

Recall@5 (R@5)

Mede se o produto correto aparece **em alguma das 5 primeiras posições** da lista de resultados, independentemente da posição exata.

$$R@5 = \frac{\text{número de queries em que o produto correto está entre os top-5}}{\text{número total de queries avaliadas}}$$

Nota: você pode ter instruído o modelo a retornar uma única sugestão ao invés de uma lista ranqueada. Nesse caso, P@1 é a métrica principal e MRR e R@5 coincidem com P@1. Isso deve ser mencionado na análise comparativa.

Análise Qualitativa

Além das métricas numéricas, seu relatório deve apresentar:

- **Exemplos de acertos:** queries que foram mapeadas corretamente, com o texto da query e o produto encontrado
- **Exemplos de erros:** queries que falharam, com análise do motivo (ex: "o modelo confundiu Coca-Cola 1L com Coca-Cola 2L porque a quantidade de litros não foi tratada no pré-processamento")
- **Casos ambíguos:** queries onde mais de um produto do catálogo seria uma resposta válida
- **Casos NO_MATCH :** queries para as quais o produto não existe no catálogo — como cada abordagem se comporta nesses casos?

Comparação das Abordagens

Apresente uma tabela comparativa como a seguinte:

Abordagem	P@1	MRR	R@5	Tempo (250 queries)	Custo	Complexidade
TF-IDF / BM25	?	?	?	?	Gratuito	Baixa
Deep Learning	?	?	?	?	Varia	Média

Entrega

- **Número de Integrantes:** de 2 a 6.
- **Data de Entrega:** 30/06
- **Formato da Entrega:** Arquivos/link no Moodle + Apresentação em Sala de Aula
 - A apresentação será feita diretamente ao professor, sem necessidade de slides formais. O foco é a discussão dos resultados e metodologia, não a qualidade visual da apresentação.

Entregáveis:

- `README.txt` contendo: nome e matrícula de todos os integrantes; instruções passo a passo para instalar as dependências e reproduzir os resultados (incluindo como configurar a variável de ambiente da API key utilizada).
- Código-fonte completo (ou link para repositório GitHub/GitLab), contendo os dois pipelines implementados e o script de avaliação.
- Relatório em PDF ou PPT contemplando:
 1. **Referencial Teórico:** descrição dos conceitos utilizados (TF-IDF, BM25, embeddings, similaridade de cosseno, LLMs) com referências bibliográficas.
 2. **Delimitação do Desenvolvimento:** o que foi reaproveitado de código de repositórios públicos e o que foi implementado pelo grupo. Deixe essa distinção clara.
 3. **Metodologia:** descrição do pipeline de cada abordagem, decisões de pré-processamento e estratégia de avaliação (validação × teste).
 4. **Resultados e Análise:** tabela comparativa das métricas, exemplos qualitativos de acertos/erros, discussão sobre os tradeoffs das abordagens.
 5. **Conclusão, Melhorias e Dificuldades:** principais aprendizados e possíveis melhorias futuras (ex: fine-tuning, modelos multilíngues, uso de dados de treinamento adicionais).
 6. **Referências**